

トランジションを考慮した 即興的なダンス生成アルゴリズム

令和8年2月13日(火曜日)

金沢工業大学 工学部 情報工学科



1254574 4EP3-29 佐々木康介

1495100 4EP4-67 クダウダゲウィドゥシャンプラバシュ

指導担当教員：山本 知仁 教授

1. 研究背景
2. 研究目的
3. 先行研究
4. システムの概要
5. 訓練と評価
6. まとめ・今後の展望

- 2024年度に開催されたパリオリンピックで新競技として「ブレイキン」が採用された。
- 大元がヒップホップの文化であるため、音楽との即時的な応答による「間」や「空気感」などの**駆け引きが関係する要素**が、観る者に強い印象を与える要因となっている。
- ブレイキンを通じて即興性や創造性、音楽性といった身体的表現が国際的な評価軸の一つとして認知されるようになったが、評価面で賛否両論が巻き起こった^[1]



<https://www2.myjcom.jp/special/olympics/paris/sports/detail.php?sports=breaking>

[1] ブレイキンにおける遊戯性について (2024)

- 一般の観客からは「間」や「空気感」などの駆け引きが関係する要素は見えにくい。そのため**客観的評価だけでは不十分**である。
- そこで、主観的評価を含めたダンスの記録と、その解析結果をモデルに導入することで、適切な評価に近づくことができると考えた。
- 本研究では、ダンサー自身の視点と客観視点を織り交ぜた評価（自己言及的フィードバック(以降セルフフィードバックとする)に該当する)を用いたダンスを構造的に再構成し生成する仕組みを考え、この構造を検討する上で鈴木らが報告した階層的意味生成構造が参考になると考えた。


鈴木ら^[2](2022)

人間の言語機能に含まれる**コア・マージ(複数の異なる要素を順序的に結合することで意味を成立する機能)**がシジュウカラの警戒音列にも観測されると報告している。



即興ダンスにおいても「順序的結合」の操作がグループ全体に意味を付与する。

鈴木ら：音素 ⇒ 文法ルール ⇒ Merge ⇒ 意味生成
本研究：Genesys ⇒ Buffer ⇒ Motion ⇒ Coherence
⇒ **構造の身体動作への拡張**が可能になる



[2] Experimental evidence for core-Merge in the vocal communication system of a wild passerine (2022)

既存の論文は、以下の4つのどれかに集約される形であり、それぞれは独立し動作の自然さやリズムへの整合性に留まるのみとなっている。鈴木らの研究は4に該当すると考えられる。

1. 文化・評価理論（思想/評価の仕方そのもの）
2. 予測・誤差最小化系（脳/制御の説明モデル）
3. 運動生成の“プリミティブ合成”系（ロボ/モーション生成）
4. 意思決定ループ系（“観測→解釈→決定→実行”）

本研究では、以上をこの順に**構造的に統合**し、ダンスアルゴリズムを「**曲に対する意味と評価を維持するための意思決定過程**」として扱う。

研究対象：佐々木自身のセルフフィードバック

- ダンス歴が8年目になり、2年ほど前からセルフフィードバックを逐一残すようになった（結果として2025年の春に行われた学内のダンスの大会で優勝している。）
- 記録を分析する中で、繰り返し出現する観点や傾向が確認されたため、整理・抽象化し、数式化可能なモデルとして表現できる段階に至った

本研究ではこのセルフフィードバックに基づいて定義した「**GBMCモデル**」というダンス生成のモデルについて説明する。

260209_これで「平等」だよな。

#Mine研究/数学

多分タイミングってのが因数分解できるんだよな。Bufferのフィルターってやつでさ。あれの Θ_3 の横軸で0.75秒とかがあった。あれで直前のタイミングを小数点第3位くらい(少なくともこれくらいだから多分エグい人はもっと細かい調節できると思う。)まで調整できるのよな。


全員が平等の立場に立てるか。多分俺にとってのGBMCがそうだな。なおこの世界における「平等」ってのはあるのよ。なんだけどここには「気が狂うほどの努力量」が必要になんよ。もっと言うと「一回自分自身を疑って『なぜ?』を繰り返す」という工程が要るのよww んでもってこれが精神に対する修行でさ。要は自分自身を研磨するみたいなことなんだけだ。多分だけども是非でも「自分の人生を設計する」みたいな方向に舵を切ることになるんだよな。

これを設計するのがめっちゃ大変な作業でな。俺もやったんだけど「自分がかけたコスト == 該当する哲学」というものを探すことなのよ。コストと哲学が等しくなるのが正解(んどこまでくると「自分のかけてきたコスト = 数学」ってのが言えるようになるんすわ)になるっていうね。

んで怖いのが、これって「社会から言われてる入口への正規の入り方が『なんか違うなあ』の人」が該当すんのよ。俺は環境が俺に合わせてくれたからどうにかなったんだけどね。本当に幸運。だって救われない人もいるんやぜ? 合わせられずに「まあ頑張ってくれよ」の人がいるんだもん。しかも俺は本当に合ってるかを大学4年間使って確認する羽目になったわ、クソがよっ。

んでドロップアウトする人もこれに該当します。何なら上手くいく人なんて2割もないでしよw 俺は山本研っていう頭良いとこに入れたから、これをちゃんと言語化できる正当な後ろ盾を得られたんだけど、本来の道の人はこれを無視するんだ。まあ「救える時にでも救っとけ」精神なんどね。

以下の図が「GBMCモデル」として定義したループ構造になる



- GBMCモデル：Genesis ⇔ Buffer ⇔ Motion ⇔ Coherence
 - Genesis：「身体動作の選択肢を選ぶ」層
 - Buffer：「選んだ選択肢を曲に合わせて自己解釈する」層
 - Motion：「実際に行動して結果を待つ」層
 - Coherence：「周囲の反応から自分の決定に対する比較を行う」層

遷移内容は以下のようにになっている

- Genesis→Buffer：動作の文脈が発生し、候補が生成される
- Buffer→Motion：候補に対する内部評価から遷移可能なものを1つ選択する
- Motion→Coherence：自分の起こした行動と周囲との差異を見る
- Coherence→Genesis：比較した内容から自分の最終決定を出力する

Genesis phase : 身体動作の選択層/選択肢の提示

「Language Modeling by Language Models (2025)」のモデルを参考になっている

$$G_{raw} = r(t) \cdot \omega \quad \Delta\sigma(t) = S(t) - \sigma_0$$

- G_{raw} : 目の前の選択肢の総量
- $r(t)$: 自己資源の残量
- ω : 個人固有の周波数[rad/s or 1/s]
- $\Delta\sigma(t)$: 時間基準 σ_0 と自分時間 $S(t)$ の差分


$$\sigma_{eff} = (1 - \alpha)\sigma_{eff}(t - 1) + \alpha\Delta\sigma(t)$$

$$Q_i(t) = \lambda(\tau_i - \tau_0)\sigma_{eff}(t)$$

- $Q_i(t)$: 内部駆動量
- σ_{eff} : 空気感における有効ズレ

$$\alpha(B) = \frac{Q_i(t)}{\Delta\sigma(t)} = \frac{\lambda(\tau - \tau_0)\sigma_{eff}(t)}{S(t) - \sigma_0}$$

- $\alpha(B)$: 場に対する許容量



Buffer phase：吸収層/様子を見る&自己解析する

本層では4層(0-3)の遷移フィルタがあり、Lv.3で**Stillness in Motion(動中静)**という特殊状態が使用可になる。

$$H(\delta_i) = \begin{cases} 0 & \delta_i < 0 \\ 1 & \delta_i \geq 0 \end{cases} \quad \delta_i = \tau_i^{req} - \tau_i^{pred}$$

$$H(\delta_i) = \lim_{k \rightarrow \infty} \sigma(k\delta_i) = \frac{1}{1 + e^{-k\delta_i}}$$

$H(\delta_i)$ ：Sigmoid関数の遷移条件[0/1]

δ_i ：本来必要とする時間[s]


$$p_{trans}(t) = \sigma(k(t)\delta_i)$$

$p_{trans}(t)$ ： $H(\delta_i)$ の中身[0,1]

$$\lim_{k(t) \rightarrow \infty} p_{trans}(t) = H(\delta_i) \quad k(t) \in \Theta_k$$

Θ_k ：Lv.0-3の全4階層フィルタそのもの

$k(t)$ ： Θ_k に対する時間感度変数



Buffer phase：吸収層/様子を見る&自己解析する

本層では4層(0-3)の**遷移フィルタ**があり、Lv.3で**Stillness in Motion(動中静)**という特殊状態が使用可になる。

動中静の数式表現がこちらになる： $\Theta_3 = \{x \in \mathbb{R} | 0 \leq x \leq \max(\Theta_2), 2x \in \mathbb{Z}\}$

縦軸：要素の大きさ(A)
横軸：経過時間(T)

×：遷移不可
△：要素のみ可能
○：遷移可能

Lv.3	-1	-0.75	-0.5	-0.25	0	0.25	0.5	0.75	1
0	×	×	×	×	×	×	×	×	×
0.5	×	×	×	×	×	×	×	△	△
1	×	×	×	×	×	×	×	△	○
1.5	×	×	×	△	△	△	×	△	△
2	△	×	×	△	○	△	×	×	×
2.5	×	△	△	△	△	△	△	△	×
3	×	△	○	△	×	△	○	△	×
3.5	△	△	△	△	△	△	△	△	△
4	△	○	△	○	△	○	△	○	△

Stillness in motion(動中静)について

2EP082

Stillness in Motion(動中静)^[3]: 動作遷移の直前に生じる一時的な選択状態

武道の概念から輸入したもので、「(過去の失敗を経て)目の前の選択肢がどれに遷移しても全体としては破綻しなくなった状態」を指す。


数式表現 ↓

$$C_i^{cap} \cdot C_i^{coh}(t) \in \Theta_3$$

C_i^{cap} : 選択に対する許容量(Capacity)

$C_i^{coh}(t)$: 全体の整合性(Coherence)[s]

Θ_3 : BufferのLv.3フィルタ




Stillness in motion(動中静)について

2EP082

通常、Buffer時点の自己解像度はMotionで得られる客観度合いを含まず、なおかつ時間遷移で相転移するため、「自己解像度>客観度合い」とはならない。

⇒「挑戦して失敗した」や「悔しいから努力する」などで**自己投資としてコストを支払った分だけ、「新規事象に対する解像度が上昇」**するため、**(意図的に)遊べるほどの余裕を作れる**ようになる。

Lv.0	0	1
1	×	○
2	○	×
3	×	×



Lv.3	-1	-0.75	-0.5	-0.25	0	0.25	0.5	0.75	1
0	×	×	×	×	×	×	×	×	×
0.5	×	×	×	×	×	×	×	△	△
1	×	×	×	×	×	×	×	△	○
1.5	×	×	×	△	△	△	×	△	△
2	△	×	×	△	○	△	×	×	×
2.5	×	△	△	△	△	△	△	△	×
3	×	△	○	△	×	△	○	△	×
3.5	△	△	△	△	△	△	△	△	△
4	△	○	△	○	△	○	△	○	△

状態遷移の定義：

$$state(t) \in \{0, 1, 2, 3\} \quad \Delta t_i := t - t_{enter,i} \quad \delta_i := \Delta t_i - \rho \cdot \tau_i$$

δ_i ：本来必要とする時間[s]

自己潜在時間の定義：

$$\tau_i^{pred} = f\{S, G, B, Q, C^{cap}, C^{coh}, D, M\} \quad \tau_i^{pred} := \rho \cdot \tau_i$$

τ_i^{pred} ：世界時間の遷移(に必要な要素の集合)[s]

発生するコスト/ノイズ：

$$\tau_i^{req} = \frac{1}{C_i^{cap}} \int_0^t S(u) \frac{d\hat{t}}{dt} du \quad \tau_i^{req} := \Delta t_i \quad C_i^{coh} = \exp(\tau_i^{req})$$

τ_i^{req} ：主観時間の遷移(のために費やした努力などのコスト量)[s]

遷移結果：努力の先に辿り着く解像度

$$\Theta_3 = \{x \in \mathbb{R} | 0 \leq x \leq \max(\Theta_2), 2x \in \mathbb{Z}\}$$



$$C_i^{cap} \cdot C_i^{coh}(t) \in \Theta_3$$

Buffer⇒Stillness in Motion(動中静)の遷移、裏では以下のようなシステム構造となっている。

$$\bar{S}(t) = (1 - \alpha_S)\bar{S}(t-1) + \alpha_S S(t)$$

$$\gamma(t) = \frac{d\hat{t}}{dt} = \frac{S(t)}{\bar{S}(t) + \epsilon} \quad (\epsilon > 0)$$

$$\hat{t}(t) = \int_0^t \gamma(u) du$$

$$D(t) = \int_0^t S(u) \gamma(u) du = C_i^{cap} \cdot \tau_i^{req}$$

- $\bar{S}(t)$: 場の瞬間的な空気感強度
- $\gamma(t)$: 体感時間の進行状況
- $\hat{t}(t)$: 体感時間の総量
- $D(t)$: 未選択状態で蓄積された場のエネルギー量 = Stillness in Motion(動中静)の内部エネルギー表現

実際の即興ダンスの環境ではどう適応されるか

前提となるダンス環境の条件 ↓

- 時間が流れ続ける = 音楽が止まらない (こればかりはダンサーからはどうしようもない)
- 次の拍が必ず来る (「Stillness in Motion」により拍の無視ができる = 選択肢の幅が拡大される)
- 失敗してもリセットされない (リカバリーできないと無理)
- 他者・音・空間によって即座に反応を返される (楽しめなければ終わる)

「Stillness in Motion」を使用すると、上記の条件に「**一瞬の停止**」が強制的に発生することになる
⇒ **流れた曲の流れに沿った選択肢が生み出される** (Genesisが発生する) ことで、「今、どれを選ぶか」を即座に決める必要が出てくる。


Motion phase：行動層/実際に行動してみて結果を待つ
試用として様々な可能性に挑戦する。

数式表現 ↓

$$M(t) = \frac{G(B) \cdot C_i^{coh}(t)}{\Delta\sigma(t)}$$

以下が要素配分である

- $\Delta\sigma(t)$ ：自分が背負える器[s]
- $C_i^{coh}(t)$ ：Coherence(整合性)
- $G(B)$ ：Genesis(自分基準の意見)
- $M(t)$ ：Motion(実際に行う行動)[s]



Coherence phase：整合層/周囲と自分を比較して修正点を探る

自分の行動を鑑みて発見した差分から修正点を抽出する。


数式表現 ↓

$$C_i^{coh} = \exp(\tau_i^{req}) = \lim_{n \rightarrow \infty} \left(1 + \frac{\tau_i^{req}}{n} \right)^n$$

ネイピア数の定義になる

⇒ 一步ずつの修正を大量に行う為

- τ_i^{req} ：自己意識の時間軸[s]
- C_i^{coh} ：全体への整合性(Coherence)




ダンスを解析するライブラリやデータベースは既存で多数存在している。

- MediaPipe(Google社のオープンソースライブラリ)
- OpenPose
- AIST Dance Video Database(国立研究開発法人産業技術総合研究所 (AIST) のデータベース)

⇒ 主観的表現はできないため一貫性がなく、その分データ量も重くなる。

そのため本研究では、モーションデータのデータセットと教師あり学習モデルを用いて、検索機能を用いた即興ダンスの物理的再現を試みる。




パイプラインの設定

1. Multimodal Perception : リアルタイムで33の音響特徴 (MFCC, Chroma, Onsets) を抽出する
2. Neuro-Symbolic Logic : エントロピー解析に基づき、ダンススタイルと強度を決定する
3. Residual Trajectory Synthesis : GRUベースのGeneratorでポーズを生成する
4. Stochastic Sequence RAG : NSLに基づき、DBから最適な実データを検索する
5. Kinetic Post-Processing : 正規化とAlpha-Blendingで滑らかでトランジションを再現する

Conditional GAN (条件付き敵対的生成ネットワーク)
アーキテクチャ

入力 : Noise (ノイズ) + Entropy (エントロピー)
Logic + Generator / 「どのように動くか」を決定
Retrieval System / 「どのように見えるか」を決定



データリソース：NTUで基礎を学び（**背骨**）、BRACEでダンスを学ぶ（**専門技術**）

• NTU-RGB-D 120

- 人物行動認識のためのデータセット
- 120のアクションクラスを収録
- アクションの標本として採用

Sample frames of "NTU RGB+D 120" dataset



Original NTU Skeleton (25 Joints)



Dataset Version	Extended (NTU RGB+D 120)
#Videos	114,480
#Classes	120
#Subjects	106
ST-LSTM [48]	55.7% 57.9%
MTLN [49]	58.4% 57.9%



• BRACE (Vector:Json, Audio:npz)

- ブレイキンに特化したデータセット
- クラス: Toprock, Footwork, Powermove
- YouTube: Red Bull BC One大会（2011～2020年）



変換アダプター

Frames	334,538
Manually annotated frames	26,676 (8%)
Duration	3h 32m
Dancers	64
Videos	81
Sequences	465
Segments	1,352
Avg. segments per sequence	2.91
Avg. sequence duration	27.48s
Avg. segment duration	9.45s



スケルトン・ジョイントマッピング

欠損した脊椎を復元

[4] NTU RGB+D 120: A Large-Scale Benchmark for 3D Human Activity Understanding[arXiv:1905.04757v2 [cs.CV] 10 Jun 2019]


[5] BRACE: The Breakdancing Competition Dataset for Dance Motion Synthesis : Davide Moltisanti, Jinyi Wu, Bo Dai, Chen Change Loy[Submitted on 20 Jul 2022 (v1), last revised 22 Jul 2022 (this version, v2)]

学習戦略：物理法則の習得から即興表現へ

基礎物理の習得

NTU RGB+D 120データセットの導入

- 目的：事前学習 (Pre-training)
- ダンスの前に、まず人間としての『動きの限界』を学習
- 関節の制約**（例：膝の屈曲）や重力の影響を考慮
- 25関節 (3D座標)





転
移
学
習

ドメイン固有動作の習得

BRACEデータセットの導入

- 目的：ドメイン適応 (Fine-tuning)
- ブレイキン**に特化したドメイン固有の知識
- 13関節 (2D座標)
-  **スケルトン**：2,704サンプル /  **オーディオ**：465ファイル
- 同じ曲でも異なる表現が可能（多様性の確保）



音と動きの同期

モデルアーキテクチャの構築

2EP082


コアエンジン：HPI-GCN-OPと転移学習戦略

HPI-GCN-OP Model


High-Performance Inference Graph Convolutional Network (Over-Parameterized)

物理法則（重力・運動連鎖）をグラフとして学習可能

転移学習戦略(Transfer Learning) "PRE-TRAIN, REPLACE HEAD, FINE-TUNE"




- **Backbone**の維持：物理法則、関節、重力の情報を保持(like understanding balance, coordination, timing)
- 「**Head**」の切り離し：NTUクラスを出力する層の除去
- 新しい「**Head**」の結合：BRACEのクラスを出力する層の取り付け(Toprock、Footwork、Powermoveといった動作の違いの学習)




学習と評価：識別器の完成度

- ブレイキン独自の幾何学パターンを完全習得
 - 厳格な教師(Strict Teacher)の誕生:
Generatorへの最強のフィードバック
- ⇒ ブレイキンに関しては「本物のダンス」に直に触れているため、一定までは判定できる。




分類精度: 98.15%
(Almost Perfect)



誤判定ゼロ
(Zero False Positives)

推論結果 (Inference Check)


Sample #1112
TRUE LABEL: Powermove
AI PREDICT: Powermove
(100.0%)



Sample #155
TRUE LABEL: Powermove
AI PREDICT: Powermove
(100.0%)



Sample #632
TRUE LABEL: Footwork
AI PREDICT:
Footwork (100.0%)



学習戦略：マルチタスク損失による生成器の最適化

マルチタスク学習の目的:


ダンサーとしての「人間らしさ」と「音楽性」を両立させるための**加重和損失 (Weighted Sum of Loss)**を導入すること

$$Loss_{total} = \lambda_1 Loss_{adv} + \lambda_2 Loss_{anat} + \lambda_3 Loss_{div}$$

主要な損失関数 (Loss Components) と役割:

-  **Adversarial (敵対的)**: リアリズム追求 (98%精度) 「HPI-GCNによる厳格な判定」
-  **Anatomy (解剖学的)**: 物理的整合性 (No Broken Bones) 「関節長固定・オンセット同期」
-  **Diversity (多様性)** : モード崩壊の回避 (Creativity) 「同じ入力でも異なる出力を生成」

チューニング戦略 (Our Strategy)

安定性 (Anchor) と 多様性 (Diversity) を最優先に設定  最適化 Resurrection (ダンスの再構築) を実現

生成器の分析：『確率の雲』と物理的課題

- GRU (Gated Recurrent Unit)

ベースのGeneratorを採用

⇒ 時系列の人物動作における標準的な手法

- 新規Neural Networkを構築

⇒ ボーン（骨格）のランダムな一連の動きを生成する。


- 意図は捉えているが、身体の硬さを無視している。

マニホールド（多様体）への投影：


- 最近傍探索を用いて、これらの確率の雲を有効な人間ポーズのマニホールドへ向かう。
- AIは『振付』を描き、データベースが『身体』を与える。

相関行列 (Correlation Matrix)

[関節間の距離や角度に矛盾が生じ: 物理的破綻]



多様体への投影 (Manifold Projection)



平滑化技術



Retrieval (検索) ベースのデコードスキームによるデプロイ
生成された軌跡を用い、実モーションデータベースを検索する。

- AIの軌跡に一致する、実際の人間の骨格データを見つけ出す。





結果: 生成された『幻覚 (Hallucination)』を、実データの『多様体 (Manifold)』へ投影する。

1. 高解像度モーションライブラリのロード
2. 高忠実度(High Fidelity)なMotion Matchingの実行
3. 運動学的な平滑化のためのSavitzky-Golayフィルタの適用
 - 急激な動き (ピーク) を潰さずにノイズだけ取る
4. モーショントレールを用いた最終デモのレンダリング

ぐちゃぐちゃした線
(AIの生成)

綺麗な骨格
(DB検索後)

AI = Choreography
DB = Anatomy
補正成功




Final Architecture Result: Raw Output vs. Decoded Manifold

Raw Generator Output



Final Production Output



AIの『意思決定』プロセス

(エントロピー駆動型の多様性):

- KQI Engine (Logic) と MineLife Buffer (Subconscious) を統合し、AIに「内部的な気分の変化」を付与
- Logicモジュールがエントロピーを読み取り「Attack/攻め」か「Freeze/静止」かの意思決定を実行


Symbolic Cognitive Architecture/GBMCループ:

1. **Genesis** : 音楽の強弱が生み出す「衝動 (Drive) 」
2. **Quality** : 音楽信号の明瞭度
3. **Coherence**: 特定のスタイルの継続性 (フロー)
4. **Depth** : 複雑な動作 (Complex move) を実行する最終的な確率

GBMC(時系列データ) ⇔ CCQSGDM/GQCD(状態データ)
SとMは「Stillness in Motion」という形で実装した

デバッグ・可視化機能:

- Ghost Tracing : 動作の流動性を検証するための残像表示。
- KQI Dashboard: GenesysやDepthなどの指標をリアルタイムで計測。




聴覚から動作生成までの高速処理

リアルタイム処理の4ステップ (The Live Cycle):

1. **LISTEN** : マイクから0.5秒のオーディオチャンクを取得。
2. **ENCODE** : 33次元の特徴ベクトル (MFCC/Chroma/Onset) に変換。
3. **THINK (SLM)**: エントロピーに基づき、ToprockからPowermoveへの遷移などを即座に判断。
4. **PERFORM** : 動作の1フレームを生成し、遅延なくレンダリング。

システムベンチマーク (Performance Verification):

- 初回のロード時間を除き、定常状態での合計レイテンシ (Total Latency) は約18ms~20msを維持。
- リアルタイムの成立条件: 処理時間が入力チャンク (0.5s = 500ms) を大幅に下回るため、バッファオーバーフローのない安定したストリーミングが可能。



Most common label patterns per sequence:

(toprock, powermove, footwork)	172
(toprock, footwork)	70
(toprock, powermove)	69
(toprock, footwork, powermove)	60
(powermove,)	28
(footwork,)	20
(powermove, footwork)	19
(powermove, toprock, footwork)	11
(footwork, powermove)	5
(powermove, toprock)	4

```
--- LIVE SYSTEM COMPONENT BENCHMARK ---
1. Loading Models... DONE (0.7218s)

2. Running 5 Mock Cycles (Input: Random Noise)

--- Cycle 1 ---
[Audio Extract] : 1940.39 ms
[Brain Decide]  : 0.18 ms
[Generator]     : 88.70 ms
[Neural Search] : 46.86 ms
>> TOTAL LATENCY: 2076.12 ms
❌ CRITICAL: Latency > 0.5s (Will cause buffer overflow)

--- Cycle 2 ---
[Audio Extract] : 6.98 ms
[Brain Decide]  : 0.16 ms
[Generator]     : 7.63 ms
[Neural Search] : 5.83 ms
>> TOTAL LATENCY: 20.61 ms
✅ OK (Real-time feasible)

--- Cycle 3 ---
[Audio Extract] : 6.69 ms
[Brain Decide]  : 0.11 ms
[Generator]     : 5.70 ms
[Neural Search] : 5.79 ms
>> TOTAL LATENCY: 18.28 ms
✅ OK (Real-time feasible)

--- Cycle 4 ---
[Audio Extract] : 6.61 ms
[Brain Decide]  : 0.11 ms
[Generator]     : 5.77 ms
[Neural Search] : 5.82 ms
>> TOTAL LATENCY: 18.35 ms
✅ OK (Real-time feasible)
```

リアルタイム性の証明
(Feasibility Proof)



SPECTRAL PERCEPTION (MFCC 1-20)



SASAKI DEPTH (D): 13849447424.00

KINETIC DRIVE: 0.50x

CREATIVE DRIFT: 0.00

[] TOPROCK

[] FOOTWORK

[X] POWERMOVE

[] IDLE

評価項目 (Metrics)	最適化前 (課題) 	最適化後 (本研究の成果) 
時間的一貫性	不安定・振動 (Jittery)	流動的・人間らしい (Fluid)
動作の多様性	静的・平均的ポーズ	動的・創造的 (Top-100)
身体の整合性	関節の破綻・ねじれ	100% 正常な人体構造
リズム同期	ランダム・ズレ	オンセットに完全同期

システム定義：Neural-Choreographer (ニューラル振付師)

- 1. RAG (検索型生成) の革新:** 単なる「クリーンアップ」ではなく、動作の語彙として活用
- 2. 役割分担:** AIが「タイミングと意図」を提供し、データベースが「人間の真実性」を提供
- 3. 架け橋:** 確率的状態プランナー (Stochastic State Planner) が両者を統合

今後の展望 (Future Work)

- 1. 🎵 感情表現:** 楽曲のムード (悲哀・歓喜) に基づくスタイルの自動変化
- 2. 👯 グループダンス:** 複数エージェント間の協調動作の実装